

8. ¿Qué son los metadatos?

Respuesta:

Escribe tu respuesta aquí...

Actividad 2: Desarrollo Práctico - Exploración de Dataset

Paso 0: Importar librerías necesarias

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Configuración para visualizaciones
plt.style.use('seaborn-v0_8-whitegrid')
%matplotlib inline

print("Librerías importadas correctamente")
```

Librerías importadas correctamente

Paso 1: Selección del Dataset

Ingresa a [Kaggle Datasets](#) y selecciona un dataset de tu interés.

Datasets recomendados:

- [Titanic - Machine Learning from Disaster](#)
- [Iris Species](#)
- [Sales Dataset](#)

Pregunta 1: ¿Qué dataset seleccionaste? ¿Por qué te interesa? Indica la URL.

Respuesta:

- Nombre del dataset: *Escribe aquí...*
- URL: *Escribe aquí...*
- Razón de interés: *Escribe aquí...*

Paso 2: Carga del Dataset

Puedes cargar el dataset de varias formas:

1. Subiendo el archivo CSV a Colab
2. Usando una URL directa
3. Usando la API de Kaggle (requiere configuración)

```
# OPCIÓN A: Cargar desde URL directa (ejemplo con Titanic)
url = 'https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv'
df = pd.read_csv(url)

# OPCIÓN B: Si subiste un archivo a Colab, descomenta la siguiente línea:
# df = pd.read_csv('nombre_de_tu_archivo.csv')

print("✅ Dataset cargado exitosamente")
```

✅ Dataset cargado exitosamente

```
# Mostrar las primeras 5 filas
df.head()
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S

Pasos siguientes:

Generar código con df

New interactive sheet

Mostrar las últimas 5 filas
df.tail()

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.00	NaN	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.00	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.45	NaN	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.00	C148	C

Pregunta 2: ¿Cuántas filas y columnas tiene el dataset?

Obtener dimensiones del dataset
filas, columnas = df.shape
print(f"📊 El dataset tiene:")
print(f" - Filas (registros): {filas}")
print(f" - Columnas (variables): {columnas}")
print(f" - Tamaño total de datos: {filas * columnas} celdas")

📊 El dataset tiene:
- Filas (registros): 891
- Columnas (variables): 12
- Tamaño total de datos: 10692 celdas

❏ Paso 3: Identificación de Tipos de Datos

Ver tipos de datos por columna
print("📄 TIPOS DE DATOS POR COLUMNA:")
print("="*50)
print(df.dtypes)

📄 TIPOS DE DATOS POR COLUMNA:
=====

PassengerId int64
Survived int64
Pclass int64
Name object
Sex object
Age float64
SibSp int64
Parch int64
Ticket object
Fare float64
Cabin object
Embarked object
dtype: object

Información general del dataset
print("📄 INFORMACIÓN GENERAL DEL DATASET:")
print("="*50)
df.info()

📄 INFORMACIÓN GENERAL DEL DATASET:
=====

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):

```

# Column      Non-Null Count  Dtype
---  -
0 PassengerId  891 non-null    int64
1 Survived    891 non-null    int64
2 Pclass      891 non-null    int64
3 Name        891 non-null    object
4 Sex         891 non-null    object
5 Age         714 non-null    float64
6 SibSp       891 non-null    int64
7 Parch       891 non-null    int64
8 Ticket      891 non-null    object
9 Fare        891 non-null    float64
10 Cabin      204 non-null    object
11 Embarked   889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB

```

```

# Clasificar columnas por tipo
numericas = df.select_dtypes(include=['int64', 'float64']).columns.tolist()
categoricas = df.select_dtypes(include=['object', 'category']).columns.tolist()
fechas = df.select_dtypes(include=['datetime64']).columns.tolist()

print("📊 CLASIFICACIÓN DE VARIABLES:")
print("="*50)
print(f"\n🔢 Variables numéricas ({len(numericas)}):")
for col in numericas:
    print(f"    - {col}")

print(f"\n🏷️ Variables categóricas ({len(categoricas)}):")
for col in categoricas:
    print(f"    - {col}")

print(f"\n📅 Variables de fecha ({len(fechas)}):")
for col in fechas:
    print(f"    - {col}")

```

```

📊 CLASIFICACIÓN DE VARIABLES:
=====

🔢 Variables numéricas (7):
- PassengerId
- Survived
- Pclass
- Age
- SibSp
- Parch
- Fare

🏷️ Variables categóricas (5):
- Name
- Sex
- Ticket
- Cabin
- Embarked

📅 Variables de fecha (0):

```

Pregunta 3: ¿El dataset es principalmente estructurado o semiestructurado? Justifica tu respuesta.

Respuesta:

Escribe tu análisis aquí...

▼ Paso 4: Análisis de Valores Nulos y Duplicados

```

# Detectar valores nulos
print("❌ VALORES NULOS POR COLUMNA:")
print("="*50)
nulos = df.isnull().sum()
porcentaje_nulos = (df.isnull().sum() / len(df) * 100).round(2)

nulos_df = pd.DataFrame({
    'Valores Nulos': nulos,
    'Porcentaje (%)': porcentaje_nulos
})


```

```
# Mostrar solo columnas con nulos
nulos_df[nulos_df['Valores Nulos'] > 0]
```

✖ VALORES NULOS POR COLUMNA:

	Valores Nulos	Porcentaje (%)	
Age	177	19.87	
Cabin	687	77.10	
Embarked	2	0.22	

```
# Visualización de valores nulos
plt.figure(figsize=(10, 6))
sns.heatmap(df.isnull(), yticklabels=False, cbar=True, cmap='viridis')
plt.title('Mapa de calor de valores nulos')
plt.tight_layout()
plt.show()
```



```
# Detectar duplicados
duplicados = df.duplicated().sum()
print(f"📄 DUPLICADOS: {duplicados} filas duplicadas ({(duplicados/len(df)*100):.2f}% del total)")
```

📄 DUPLICADOS: 0 filas duplicadas (0.00% del total)

Pregunta 4: ¿Qué columnas tienen valores nulos? ¿Qué estrategia sugerirías para tratarlos?

Respuesta:

Escribe tu análisis aquí...

▼ Paso 5: Estadísticas Descriptivas

```
# Estadísticas descriptivas de variables numéricas
print("📊 ESTADÍSTICAS DESCRIPTIVAS - VARIABLES NUMÉRICAS:")
print("="*70)
df.describe()
```

ESTADÍSTICAS DESCRIPTIVAS - VARIABLES NUMÉRICAS:

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200

```
# Estadísticas de variables categóricas
print("ESTADÍSTICAS - VARIABLES CATEGÓRICAS:")
print("=="*70)
df.describe(include='object')
```

ESTADÍSTICAS - VARIABLES CATEGÓRICAS:

	Name	Sex	Ticket	Cabin	Embarked
count	891	891	891	204	889
unique	891	2	681	147	3
top	Dooley, Mr. Patrick	male	347082	G6	S
freq	1	577	7	4	644

```
# Conteo de valores únicos por columna
print("VALORES ÚNICOS POR COLUMNA:")
print("=="*50)
for col in df.columns:
    print(f"{col}: {df[col].nunique()} valores únicos")
```

VALORES ÚNICOS POR COLUMNA:

```
=====
PassengerId: 891 valores únicos
Survived: 2 valores únicos
Pclass: 3 valores únicos
Name: 891 valores únicos
Sex: 2 valores únicos
Age: 88 valores únicos
SibSp: 7 valores únicos
Parch: 7 valores únicos
Ticket: 681 valores únicos
Fare: 248 valores únicos
Cabin: 147 valores únicos
Embarked: 3 valores únicos
```


Pregunta 5: ¿Cuáles son las principales estadísticas de las variables numéricas?

Respuesta:

Escribe tu análisis aquí...

▼ Paso 6: Visualización Básica


```
# Histograma de todas las variables numéricas
df.hist(figsize=(14, 10), bins=20, edgecolor='black')
plt.suptitle('Distribución de Variables Numéricas', fontsize=14)
plt.tight_layout()
plt.show()
```



```
# Boxplots para detectar outliers en variables numéricas
numericas = df.select_dtypes(include=['int64', 'float64']).columns

fig, axes = plt.subplots(nrows=1, ncols=len(numericas[:4]), figsize=(16, 5))
for i, col in enumerate(numericas[:4]):
    df.boxplot(column=col, ax=axes[i])
    axes[i].set_title(col)

plt.tight_layout()
plt.show()
```




```
# Gráfico de barras para variables categóricas
categoricas = df.select_dtypes(include=['object']).columns


fig, axes = plt.subplots(nrows=1, ncols=min(3, len(categoricas)), figsize=(15, 5))
if len(categoricas) == 1:
    axes = [axes]

for i, col in enumerate(categoricas[:3]):
    df[col].value_counts().plot(kind='bar', ax=axes[i], color='steelblue', edgecolor='black')
    axes[i].set_title(f'Distribución de {col}')
    axes[i].tick_params(axis='x', rotation=45)

plt.tight_layout()
plt.show()
```



```
# Matriz de correlación (solo variables numéricas)
plt.figure(figsize=(10, 8))
correlacion = df.select_dtypes(include=['int64', 'float64']).corr()
sns.heatmap(correlacion, annot=True, cmap='coolwarm', center=0, fmt='.2f')
plt.title('Matriz de Correlación')
plt.tight_layout()
plt.show()
```

Pregunta 6: ¿Qué patrones observas en las distribuciones?

Respuesta:

Escribe tu análisis aquí...

✓ Actividad 3: Caso de Estudio - Documentación del Dataset

Contexto: Eres un analista de datos junior en una empresa y te han asignado la tarea de documentar un nuevo dataset que la empresa ha adquirido.

Pregunta A: Ficha Técnica del Dataset

Elabora una ficha técnica que incluya:

- Nombre del dataset
- Fuente
- Fecha de descarga
- Número de registros
- Número de columnas
- Tipos de datos presentes
- Tamaño del archivo

Respuesta:

Campo	Valor
Nombre del dataset	<i>Escribe aquí</i>
Fuente	<i>Escribe aquí</i>
Fecha de descarga	<i>Escribe aquí</i>
Número de registros	<i>Escribe aquí</i>
Número de columnas	<i>Escribe aquí</i>
Tipos de datos	<i>Escribe aquí</i>

Pregunta B: Dimensiones de Calidad de Datos

Identifica cuáles de las siguientes dimensiones de calidad están presentes en tu dataset:

- Completitud
- Exactitud
- Consistencia
- Oportunidad
- Unicidad

Respuesta:

Escribe tu análisis aquí...

Pregunta C: Clave Primaria

Si tuvieras que crear una tabla en una base de datos para almacenar este dataset, ¿qué columnas elegirías como clave primaria? ¿Por qué?

Respuesta:

Escribe tu análisis aquí...

Pregunta D: Valor de Negocio

¿Qué valor de negocio podría tener este dataset? Menciona al menos 2 preguntas de negocio que podrían responderse con estos datos.

Respuesta:

Escribe tu análisis aquí...
