

Pasión por la

Tecsup®

Tecnología

Fundamentos de Gestión de Datos

Docente:
Pilar Rocío Sayán Mejía

**LABORATORIO
CALIFICADO N° 01**

Semana 1 y 2

Tecsup®

LABORATORIO CALIFICADO N° 02 Semana 1 y 2	
DOCENTE: Pilar Rocío Sayán Mejía	CURSO: Fundamentos de Gestión de Datos

Sección:	Fecha:

Integrantes del grupo:	
1. 	2.
3. 	4.

I. ELEMENTO DE LA CAPACIDAD TERMINAL

Identifica la estructura de un conjunto de datos, diferencia variables cuantitativas y cualitativas según su naturaleza y tipo de dato, interpreta la información contenida en un DataFrame y analiza datasets utilizando operaciones básicas de exploración y estadística descriptiva en Python y pandas.

II. SEGURIDAD

- Está prohibida la manipulación de hardware o conexiones eléctricas/de red sin supervisión.
- No consumir alimentos ni bebidas durante la sesión.
- Guardar maletines y mochilas en el lugar asignado.
- Dejar la mesa de trabajo y la silla limpias y ordenadas.
- No instalar software no autorizado.
- Todo el trabajo debe desarrollarse únicamente en Google Colab.

III. FUNDAMENTO TEÓRICO

Revisar antes de iniciar el laboratorio:

- McKinney, W. (2022). *Python for Data Analysis* (3.a ed.). O'Reilly Media. Caps. 1-5.
- VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly Media. Caps. 2 y 3.
- Documentación oficial de pandas: <https://pandas.pydata.org/docs/>
- Diapositivas de las Semanas 1 y 2 del curso.

Conceptos clave: dataset, fila, columna, variable, DataFrame, tipos de datos (int64, float64 y object), variables cuantitativas y cualitativas, variables discretas y continuas, estadísticas descriptivas, .shape, .dtypes, .info() y .describe().

IV. RECURSOS

- Computadora con acceso a internet y navegador web.
- Cuenta de Google para acceso a Google Colab.
- Python 3.x con pandas preinstalado en Colab.
- Dataset mtcars desde URL pública.
- Scripts y notebooks proporcionados en el aula virtual.

V. METODOLOGÍA PARA EL DESARROLLO

El laboratorio se desarrolla de manera individual.

Indicaciones generales:

- ▶ Ejecutar cada celda en orden.
- ▶ Analizar cuidadosamente los resultados antes de responder.
- ▶ No eliminar ni modificar el código proporcionado.
- ▶ Las respuestas deben redactarse con interpretación propia y enfoque analítico.
- ▶ Todas las conclusiones deben estar contextualizadas en el caso presentado.

Cada estudiante debe colocar su nombre completo en el encabezado del notebook antes de iniciar el desarrollo.

Introducción — Conceptos clave

¿Qué es una variable?

Una variable es cada columna de un conjunto de datos.

Representa una característica que se mide u observa en cada registro (fila).

Clasificación de variables

Tipo	Subtipo	Descripción	Ejemplo
Cuantitativa	Continua	Toma cualquier valor numérico en un rango	Peso: 65.3 kg, temperatura: 36.7 °C
Cuantitativa	Discreta	Solo valores enteros contables	Número de hijos: 0, 1, 2, 3
Cualitativa	Nominal	Categorías sin orden entre sí	Color, país, género
Cualitativa	Ordinal	Categorías con orden lógico	Nivel: básico < medio < superior

Tipos de dato en pandas

Tipo pandas	Significado	Tipo de variable probable
float64	Número decimal	Cuantitativa continua
int64	Número entero	Cuantitativa discreta o cualitativa (si son códigos)
object	Texto	Cualitativa nominal

> Importante: Un int64 no siempre es cuantitativo.

> Si los valores son códigos (0 = No, 1 = Sí), la variable es cualitativa nominal.

Tabla de conceptos — completa ANTES de iniciar el laboratorio

Esta tabla se evalúa. Escribe con tus propias palabras.

Concepto	Definición con tus propias palabras
Variable cuantitativa continua	
Variable cuantitativa discreta	
Variable cualitativa	
DataFrame	
float64	
int64	
object	
.shape	

.dtypes	
.info()	

VI. PROCEDIMIENTO

CASO 1 — Dataset de automóviles (mtcars)

Contexto:

Eres analista de datos en la consultora AutoData S.A. Un cliente fabricante de vehículos te entrega el dataset *mtcars*, el cual contiene información técnica de distintos modelos de automóviles. Antes de realizar cualquier modelo predictivo o análisis avanzado, tu primera tarea consiste en comprender la estructura del dataset y clasificar correctamente las variables.

Paso 1 — Cargar el dataset desde URL

`pd.read_csv(url)` carga un archivo CSV desde internet en un DataFrame.

`index_col=0` usa la primera columna (nombre del modelo) como índice de filas.

`df.head(5)` muestra los primeros 5 registros para una revisión rápida.

```
import pandas as pd

# Cargar mtcars desde URL pública
url = 'https://raw.githubusercontent.com/vincentarelbundock/Rdatasets/master/csv/datasets/mtcars.csv'
df_autos = pd.read_csv(url, index_col=0)

print('Dataset cargado correctamente.')
print(df_autos.head(5))
```

La empresa necesita responder las siguientes preguntas:

1.

Pregunta 1.1 ¿Qué representa cada fila del dataset? ¿Y cada columna?

 Tu respuesta:

Pregunta 1.2 Como analista de AutoData S.A., ¿qué columna te parece más importante a primera vista para comparar eficiencia de combustible entre autos? ¿Por qué?

 Tu respuesta:

Paso 2 — Renombrar columnas al español

Los nombres originales son abreviaciones en inglés.

Se renombran al español para facilitar la comunicación con el cliente.

Diccionario de variables — mtcars

Variable (español)	Variable original	Descripción detallada	Tipo de dato	Tipo de variable
millas_por_galon	mpg	Consumo: millas recorridas por galón de combustible		
cilindros	cyl	Número de cilindros del motor (4, 6 u 8)		
desplazamiento	disp	Volumen total de los cilindros del motor (pulg ³)		
caballos_fuerza	hp	Potencia máxima del motor en HP		
relacion_eje	drat	Relación de transmisión del eje trasero		
peso	wt	Peso del vehículo en miles de libras		
tiempo_cuarto_milla	qsec	Segundos en recorrer un cuarto de milla		
tipo_motor	vs	Configuración: 0 = en V, 1 = en línea		
transmisión	am	Transmisión: 0 = automática, 1 = manual		
velocidades	gear	Número de marchas (3, 4 o 5)		
carburadores	carb	Número de carburadores del motor		

```
# Renombrar columnas al español
```

```
df_autos.columns = [
    'millas_por_galon', 'cilindros', 'desplazamiento',
    'caballos_fuerza', 'relacion_eje', 'peso',
    'tiempo_cuarto_milla', 'tipo_motor', 'transmision',
    'velocidades', 'carburadores'
```

```
]

print('Columnas renombradas:')
print(df_autos.columns.tolist())
print()
print(df_autos.head(3))
```

Pregunta 1.3 Consulta el diccionario. ¿Qué diferencia hay entre tipo_motor y cilindros si ambos son int64? ¿Por qué uno es cualitativo y el otro cuantitativo?

 Tu respuesta:

Pregunta 1.4 ¿Por qué transmisión tiene valores 0 y 1 pero se clasifica como cualitativa y no cuantitativa?

 Tu respuesta:

Paso 3 — Estructura del dataset

.shape devuelve (filas, columnas). Es lo primero que reportas como analista al presentar un dataset nuevo.

```
# Estructura del dataset
filas, columnas = df_autos.shape
print('Filas (registros): ', filas)
print('Columnas (variables):', columnas)
```

Pregunta 1.5 El cliente de AutoData S.A. pregunta: ¿Cuántos modelos de autos y cuántas características por modelo tiene el dataset?. Respóndele como analista, sin tecnicismos.

 Tu respuesta:

Paso 4 — Tipos de datos

.dtypes muestra el tipo de dato de cada columna.

.info() da un resumen completo: tipo, valores no nulos y uso de memoria.

Revisa esto siempre antes de analizar — un tipo incorrecto arruina los cálculos.

```
# Tipos de dato por columna
print('Tipos de dato:')
print(df_autos.dtypes)
```

```
# Información completa del dataset
df_autos.info()
```

Pregunta 1.6 ¿Cuántas variables son float64 y cuántas son int64? ¿Hay alguna object? ¿Qué significa que no haya ninguna de tipo object?

 Tu respuesta:

Pregunta 1.7 ¿Hay valores nulos en el dataset? ¿Cómo lo confirmas con .info()?

 Tu respuesta:

Paso 5 — Identificar variables cuantitativas y cualitativas

`select_dtypes(include=[...])` filtra columnas por tipo de dato.

Esto separa automáticamente las variables numéricas de las de texto.

```
# Variables numéricas
vars_numericas = df_autos.select_dtypes(include=['float64',
'int64']).columns.tolist()
print('Variables numéricas (float64 / int64):')
print(vars_numericas)

print()

# Variables de texto
vars_texto = df_autos.select_dtypes(include=['object']).columns.tolist()
print('Variables de texto (object):')
print(vars_texto)
```

Pregunta 1.8 tipo_motor, transmisión y velocidades aparecen como int64 pero son cualitativas según el diccionario. ¿Qué riesgo hay si las tratamos como números para calcular promedios?

 Tu respuesta:

Pregunta 1.9 Completa la tabla de clasificación usando el diccionario y los resultados obtenidos:

Variable	Tipo pandas	Tipo de variable real	Justificación breve
millas_por_galon	float64		
cilindros	int64		
desplazamiento	float64		
caballos_fuerza	int64		
peso	float64		

tipo_motor	int64		
transmisión	int64		
velocidades	int64		

Paso 6 — Estadísticas básicas

.describe() calcula conteo, promedio, desviación estándar, mínimo, cuartiles y máximo.

Es el resumen inicial que todo analista presenta al cliente.

```
# Estadísticas descriptivas
print('Estadísticas descriptivas de mtcars:')
print(df_autos.describe())
```

Pregunta 1.10 El cliente pregunta: *"¿Cuál es la eficiencia de combustible promedio y cuál es la diferencia entre el auto más eficiente y el menos eficiente?"*. Respóndele usando los datos del resultado.

 Tu respuesta:

Pregunta 1.11 Como analista, ¿qué conclusión le darías al cliente sobre la potencia (caballos_fuerza) de los autos del dataset? Usa mínimo, máximo y promedio.

 Tu respuesta:

PARTE 2 — Consultas SQL con SQLite: Farmacia

Crearemos una base de datos SQLite de una farmacia con tres tablas relacionadas y practicaremos consultas SQL básicas.

Regla importante: SQL puro en esta parte

Todo el filtrado, cálculo y ordenamiento se hace con SQL.

pandas solo se usa al final de cada consulta con `pd.read_sql_query()` para MOSTRAR el resultado

como tabla con encabezados claros. No usar pandas para filtrar ni calcular.

Estructura de la base de datos

La base de datos tiene tres tablas relacionadas:

clientes	(cliente_id PK, nombre NOT NULL, ciudad NOT NULL)
----------	---

medicamentos (medicamento_id PK, nombre NOT NULL UNIQUE, categoria NOT NULL, precio NOT NULL)
ventas (venta_id PK, cliente_id FK -> clientes,
medicamento, categoria, ciudad,
cantidad NOT NULL, monto NOT NULL, fecha NOT NULL)

PK = Clave Primaria | FK = Clave Foránea | NOT NULL = campo obligatorio |
UNIQUE = sin repetidos

Celda de preparación — ejecutar una sola vez

```
import sqlite3, pandas as pd, os, gc

DB_NAME = "farmacia.db"
try: cursor.close()
except: pass
try: conexion.close()
except: pass
gc.collect()
if os.path.exists(DB_NAME): os.remove(DB_NAME)

conexion = sqlite3.connect(DB_NAME)
cursor = conexion.cursor()

cursor.execute("""
CREATE TABLE clientes (
    cliente_id INTEGER PRIMARY KEY,
    nombre TEXT NOT NULL,
    ciudad TEXT NOT NULL
);""")

cursor.execute("""
CREATE TABLE medicamentos (
    medicamento_id INTEGER PRIMARY KEY,
    nombre TEXT NOT NULL UNIQUE,
    categoria TEXT NOT NULL,
    precio REAL NOT NULL
);""")

cursor.execute("""
CREATE TABLE ventas (
```

```
venta_id INTEGER PRIMARY KEY,  
cliente_id INTEGER NOT NULL,  
medicamento TEXT NOT NULL,  
categoria TEXT NOT NULL,  
ciudad TEXT NOT NULL,  
cantidad INTEGER NOT NULL,  
monto REAL NOT NULL,  
fecha TEXT NOT NULL,  
FOREIGN KEY (cliente_id) REFERENCES clientes(cliente_id)  
);"""
```

```
# Insertar 6 clientes, 6 medicamentos y 18 ventas  
# (ver notebook completo para los datos)
```

```
conexion.commit()  
def mostrar(sql): return pd.read_sql_query(sql, conexion)  
print("Base de datos farmacia.db creada correctamente.")
```

Consulta 1 — Todos los registros

SELECT * trae todas las columnas y todas las filas.

```
consulta = "SELECT * FROM ventas;"  
mostrar(consulta)
```

Pregunta SQL 1 ¿Cuántas filas devuelve? ¿Qué columnas contiene la tabla ventas?

 **Tu respuesta:** _____

Consulta 2 — Columnas específicas

Seleccionamos solo las columnas que nos interesan.

```
consulta = ""  
SELECT cliente_id, medicamento, ciudad, monto  
FROM ventas;""  
mostrar(consulta)
```

Pregunta SQL 2 ¿Qué columnas aparecen ahora? ¿Por qué es útil elegir solo algunas columnas?

 **Tu respuesta:** _____

Consulta 3 — Filtrar por ciudad: Lima

WHERE ciudad = 'Lima' filtra solo las filas de Lima.

```
consulta = ""
SELECT *
FROM ventas
WHERE ciudad = 'Lima';""
mostrar(consulta)
```

Pregunta SQL 3 ¿Cuántas ventas se realizaron en Lima? ¿Qué medicamentos se vendieron allí?

 **Tu respuesta:** _____

Consulta 4 — Filtrar Arequipa o Cusco

OR incluye filas que cumplen al menos una de las condiciones.

```
consulta = ""
SELECT *
FROM ventas
WHERE ciudad = 'Arequipa'
OR ciudad = 'Cusco';""
mostrar(consulta)
```

Pregunta SQL 4 ¿Cuántas ventas hay entre Arequipa y Cusco en total?

 **Tu respuesta:** _____

Consulta 5 — Filtrar por categoría

Filtramos solo los antibióticos.

```
consulta = ""
SELECT *
FROM ventas
WHERE categoria = 'Antibiótico';""
mostrar(consulta)
```

Pregunta SQL 5 ¿Cuántas ventas de antibióticos hay? ¿En qué ciudades se vendieron?

 **Tu respuesta:** _____

Consulta 6 — Promedio de ventas (AVG)

AVG(monto) calcula el promedio. AS asigna un nombre al resultado.

```
consulta = ""
SELECT ROUND(AVG(monto), 2) AS promedio_monto
FROM ventas;""
```

```
mostrar(consulta)
```

Pregunta SQL 6 ¿Cuál es el monto promedio de las ventas de la farmacia?

 **Tu respuesta:** _____

Consulta 7 — Venta máxima (MAX)

MAX(monto) devuelve el valor más alto.

```
consulta = ""
SELECT MAX(monto) AS monto_maximo
FROM ventas;""
mostrar(consulta)
```

Pregunta SQL 7 ¿Cuál es la venta más alta registrada?

 **Tu respuesta:** _____

Consulta 8 — Venta mínima (MIN)

MIN(monto) devuelve el valor más bajo.

```
consulta = ""
SELECT MIN(monto) AS monto_minimo
FROM ventas;""
mostrar(consulta)
```

Pregunta SQL 8 ¿Cuál es la venta más baja registrada?

 **Tu respuesta:** _____

Consulta 9 — Contar registros (COUNT)

COUNT(*) cuenta el número total de filas.

```
consulta = ""
SELECT COUNT(*) AS total_registros
FROM ventas;""
mostrar(consulta)
```

Pregunta SQL 9 ¿Cuántas ventas tiene registradas la farmacia?

 **Tu respuesta:** _____

Consulta 10 — Ordenar de mayor a menor (ORDER BY)

ORDER BY monto DESC ordena los resultados de mayor a menor.

```
consulta = ""
SELECT medicamento, ciudad, cantidad, monto
FROM ventas
```

```
ORDER BY monto DESC;""""  
mostrar(consulta)
```

Pregunta SQL 10 ¿Qué venta aparece en primer lugar? ¿En qué ciudad ocurrió?

 **Tu respuesta:** _____

PARTE 3 — Interpretación de resultados

Responde las siguientes preguntas basándote en los resultados obtenidos en las Partes 1 y 2.

Pregunta 3.1 ¿Qué ciudad presenta más ventas según las consultas SQL? ¿Qué estrategia comercial sugiere esto para la farmacia?

 **Tu respuesta:** _____

Pregunta 3.2 ¿Qué categoría de medicamento parece tener mayor monto de ventas? ¿Qué dice eso sobre los hábitos de compra?

 **Tu respuesta:** _____

Pregunta 3.3 ¿Qué información útil dan juntos el promedio, el máximo y el mínimo? ¿Por qué no bastaría con solo uno?

 **Tu respuesta:** _____

Pregunta 3.4 ¿Por qué SQL permite consultar datos directamente sin modificar el DataFrame de pandas?

 **Tu respuesta:** _____

Pregunta 3.5 ¿Cuál es la principal diferencia entre explorar datos con pandas (head, dtypes) y consultar con SQL (SELECT, WHERE)?

 **Tu respuesta:** _____

Conclusiones

Escribe tres conclusiones sobre lo que aprendiste en este laboratorio.

1. _____
2. _____
3. _____

Nombre del curso	Fundamentos de Gestión de Datos
Rúbrica	Holística
Elemento de la capacidad terminal	Identifica la estructura de un conjunto de datos, diferencia variables cuantitativas y cualitativas según su naturaleza y tipo de dato, interpreta la información contenida en un DataFrame y analiza datasets utilizando operaciones básicas de exploración y estadística descriptiva en Python y pandas.

Curso	Fundamentos de Gestión de Datos
Periodo	2026-I
Actividad	Laboratorio Calificado N.º 01
Semestre	Primero

Criterios de evaluación

Criterios a evaluar	Excelente	Bueno	Requiere mejora	No aceptable	Puntaje logrado
Criterio 1: Exploración del dataset con pandas (Parte 1)	Identifica correctamente filas, columnas, tipos de datos, variables principales y clasificación cualitativa/cuantiativa. Interpreta adecuadamente .shape, .dtypes, .info() y .describe() con análisis claro y técnico.	Identifica la mayoría de elementos correctamente, pero presenta interpretaciones parciales o poco profundas.	Reconoce parcialmente la estructura del dataset y presenta errores en la clasificación o interpretación.	No logra identificar correctamente la estructura del dataset ni interpretar los resultados.	
Criterio 2: Desarrollo de consultas SQL con SQLite (Parte 2)	Ejecuta correctamente consultas SQL usando SELECT, WHERE, AVG, MAX, MIN, COUNT y ORDER BY. Utiliza SQLite adecuadamente sin reemplazar SQL por pandas. Resultados	Ejecuta la mayoría de consultas correctamente, aunque presenta pequeños errores de sintaxis o interpretación.	Ejecuta parcialmente las consultas SQL o presenta errores frecuentes en filtros y funciones.	No logra ejecutar correctamente las consultas SQL requeridas.	

	correctos y organizados.				
Criterio 3: Interpretación y análisis de resultados (Parte 3)	Analiza e interpreta correctamente los resultados obtenidos en pandas y SQL, relacionándolos con el contexto del caso de negocio. Argumenta con claridad y criterio técnico.	Interpreta los resultados de manera general, aunque con poca profundidad analítica.	Presenta interpretaciones incompletas, confusas o poco relacionadas al caso.	No interpreta correctamente los resultados obtenidos.	
Criterio 4: Presentación, orden y documentación	El notebook y el documento Word presentan excelente organización, código limpio, buena redacción, ortografía y conclusiones claras.	Presenta buena organización general, aunque con pequeños errores de formato o redacción.	Presenta desorden, errores frecuentes de redacción o documentación incompleta.	Entrega desordenada, incompleta o difícil de comprender.	
TOTAL					Sobre 16 puntos

Acciones a cumplir

Acciones a cumplir	Menos
Puntualidad y dedicación	-1
Cumplimiento de tiempos establecidos	-1
Conclusiones: ortografía y redacción	-1

Puntaje total

Comentarios respecto del desempeño del alumno

Descripción

Descripción	Detalle
Excelente	Demuestra un completo entendimiento del problema y realiza correctamente el análisis exploratorio del dataset, consultas SQL e interpretación de resultados cumpliendo todos los requerimientos especificados.
Bueno	Demuestra un considerable entendimiento del problema y desarrolla correctamente la mayoría de actividades solicitadas.
Requiere mejora	Demuestra un bajo entendimiento del problema o desarrolla parcialmente las actividades planteadas.
No aceptable	No demuestra entendimiento del problema ni logra desarrollar correctamente las actividades solicitadas.