

Pasión por la Tecnología



Fundamentos de Gestión de Datos

Docente:
Pilar Rocío Sayán Mejía

LABORATORIO CALIFICADO N°3

Semana 5 y 6:

Limpieza de Datos y

Normalización Relacional sobre la base PMD1



LABORATORIO CALIFICADO N°3 Semana 5 y 6: Limpieza de Datos y Normalización Relacional sobre la base PMD1	
DOCENTE: Pilar Rocío Sayán Mejía	CURSO: Fundamentos de Gestión de Datos

I. OBJETIVO DEL LABORATORIO

Este laboratorio calificado es el primer avance formal del Proyecto de Mejora de Datos (PMD1). El grupo aplicará un pipeline completo de limpieza de datos sobre la base real de su caso PMD1: diagnóstico de calidad, corrección de problemas, tratamiento de outliers, normalización numérica y normalización relacional. Al finalizar, dispondrán de una base limpia y estructurada lista para análisis en etapas posteriores del proyecto.

II. ELEMENTO DE CAPACIDAD TERMINAL

Aplica técnicas de limpieza de datos, normalización numérica y normalización relacional sobre bases de datos reales usando Python y pandas en Google Colab, interpretando y documentando cada decisión técnica en el contexto del caso de negocio del grupo.

III. SEGURIDAD Y NORMAS DE TRABAJO

- Todo el código se ejecuta exclusivamente en Google Colab. No instalar paquetes locales.
- Está prohibida la manipulación de hardware o conexiones eléctricas sin supervisión.
- No consumir alimentos ni bebidas durante la sesión.
- Guardar maletines y mochilas en el lugar asignado.
- Dejar la mesa de trabajo y la silla limpias y ordenadas al finalizar.

IV. FUNDAMENTO TEÓRICO

Revisar antes de iniciar el laboratorio:

- Laboratorio Dirigido N.º 05 — Análisis Exploratorio y pipeline desde tabla desnormalizada.
- Laboratorio Dirigido N.º 06 — Pipeline de limpieza: nulos, duplicados, tipos, outliers, normalización y exportación.
- McKinney, W. (2022). Python for Data Analysis (3.a ed.). O'Reilly Media. Caps. 7–9.
- Ilyas, I. F. y Chu, X. (2019). Data Cleaning. ACM Books. Caps. 1–3.

Conceptos clave: diagnóstico de calidad, imputación, IQR, boxplot, Min-Max, Z-score, 1FN, 2FN, clave primaria, clave foránea, JOIN.

V. RECURSOS

- Computadora con acceso a internet y navegador web.
- Cuenta de Google para Google Colab.
- Python 3.x con pandas, numpy, matplotlib, seaborn, sqlite3 y requests (preinstalados en Colab).
- Base de datos del proyecto PMD1 publicada en el repositorio del grupo en GitHub https://github.com/Rociosayan/PMD1_Fundamentos_Gestion_Datos
- Notebook: LAB-C3-FGD-PSAYAN-2026-01.ipynb

VI. INSTRUCCIÓN PRINCIPAL

Para este laboratorio el grupo trabajará exclusivamente con la base de datos de su propio proyecto PMD1. Cada grupo tiene un caso diferente; no existe una base genérica ni código resuelto. Los laboratorios dirigidos D5 y D6 son su guía metodológica: revisen la estructura, pero construyan el código para su caso particular.

Reglas de oro:

- No se entrega código base. El grupo escribe todo el código desde cero, adaptado a su caso.
- La base debe cargarse desde la URL RAW de GitHub del repositorio del grupo.
- Cada decisión técnica debe justificarse en las respuestas del notebook (imputación, criterio de duplicados, clip, método de normalización, separación de entidades).
- El notebook debe ejecutar sin errores de principio a fin antes de la entrega.
- Completar la tabla de aporte al inicio del notebook de manera honesta.

VII. PROCEDIMIENTO

Datos del grupo y porcentaje de aporte

Completen la siguiente tabla al inicio del notebook. El porcentaje debe reflejar el aporte real de cada integrante.

N.º	Apellidos y nombres	Rol asumido	% de aporte	Sección A ó B

Actividad 1. Contexto y carga de la base PMD1

1. Indicar el nombre del proyecto PMD1 y describir en 2–3 oraciones el caso de negocio: ¿qué problema resuelve? ¿quién es el cliente? ¿qué datos se gestionan?
2. Colocar el enlace RAW de GitHub desde donde se carga la base (SQLite, CSV o Excel).
3. Cargar la base en Google Colab y mostrar las primeras 5 filas con `df.head()`.
4. Indicar qué representa cada fila del dataset y cuántos registros y columnas tiene.
5. Identificar si la tabla está desnormalizada: ¿qué datos se repiten fila a fila? ¿qué entidades distintas coexisten en la misma tabla?

→ **Pregunta 1: ¿Qué representa cada registro de la base PMD1 y qué entidades distintas coexisten en la misma tabla?**

Actividad 2. Diagnóstico de calidad de datos

1. Mostrar dimensiones, columnas y tipos de datos con `df.shape`, `df.info()` y `df.dtypes`.
2. Calcular valores faltantes por columna y su porcentaje respecto al total de registros.
3. Detectar duplicados exactos y posibles duplicados por claves de negocio.
4. Identificar columnas con tipos incorrectos: fechas como texto, montos con símbolos, categorías mal escritas.

5. Construir una tabla resumen con los principales problemas detectados (columna, tipo de problema, cantidad afectada).

→ **Pregunta 2: ¿Cuáles fueron los tres problemas de calidad más graves encontrados y por qué representan un riesgo para el análisis?**

Actividad 3. Limpieza de datos

1. Crear una copia del DataFrame original: `df_clean = df.copy()`.
2. Estandarizar columnas de texto: `strip`, `lower/upper` según corresponda, categorías equivalentes.
3. Corregir tipos de datos: convertir fechas (`pd.to_datetime`), montos (`pd.to_numeric`), categorías.
4. Imputar valores faltantes con una estrategia justificada según el tipo de variable (media, mediana, moda, valor constante o eliminación).
5. Eliminar o consolidar duplicados exactos y por clave de negocio, explicando el criterio usado.
6. Mostrar comparación antes/después: número de nulos, tipos corregidos y registros restantes.

→ **Pregunta 3: ¿Qué estrategia se usó para imputar valores faltantes y por qué fue la más adecuada para este caso?**

→ **Pregunta 4: ¿Qué inconsistencias de texto o tipos de datos fueron las más difíciles de corregir? ¿Qué impacto tendrían si no se corrigieran?**

Actividad 4. Tratamiento de outliers

1. Seleccionar las variables numéricas relevantes para el análisis del caso PMD1.
2. Generar boxplots para cada variable seleccionada.
3. Aplicar el método IQR para calcular los límites inferior y superior.
4. Decidir para cada variable: eliminar, transformar o `cap` con `clip()`. Justificar en el contexto del negocio.
5. Mostrar antes y después: estadísticas descriptivas y boxplots actualizados.

→ **Pregunta 5: ¿Qué outliers detectaron, qué criterio de negocio sustentó la decisión tomada y cómo afectó a las estadísticas descriptivas?**

Actividad 5. Normalización de variables numéricas

1. Seleccionar al menos tres variables numéricas limpias y relevantes para el análisis.
2. Aplicar Min-Max o estandarización Z-score según corresponda y justificar la elección.
3. Verificar con código que la transformación es correcta: rango $[0,1]$ o media ≈ 0 y desviación ≈ 1 .
4. Explicar por qué la normalización debe realizarse después de tratar nulos y outliers.

→ **Pregunta 6: ¿Qué variables normalizaron, qué método eligieron y por qué es importante el orden del pipeline?**

Actividad 6. Normalización relacional de la base

1. Identificar las entidades principales del caso PMD1 y los atributos que corresponden a cada una.
2. Crear un DataFrame independiente para cada tabla maestra con clave primaria artificial.
3. Reemplazar los textos repetidos en la tabla transaccional por identificadores numéricos.
4. Guardar todas las tablas en SQLite con `to_sql()`. Verificar con una consulta SQL básica.
5. Reconstruir la vista original usando JOIN para demostrar que la información se conserva íntegra.

→ **Pregunta 7: ¿Qué tablas construyeron, ¿cuál es la clave primaria de cada una y cómo confirma el JOIN que no se perdió información?**

Actividad 7. Cierre ejecutivo

1. Comparar `df.info()` antes y después del pipeline completo.
2. Mostrar tabla resumen: nulos antes/después, duplicados, outliers tratados y variables normalizadas.
3. Redactar tres conclusiones técnicas sobre calidad, limpieza y normalización relacional.
4. Redactar una interpretación ejecutiva (2–3 oraciones) para un jefe no técnico.

→ **Pregunta 8: ¿Cómo mejora la calidad de la base PMD1 con este pipeline y qué queda listo para las etapas siguientes del proyecto?**

III. EVIDENCIAS DE ENTREGA

- Notebook de Google Colab ejecutado sin errores, con código, tablas, gráficos y respuestas visibles.
- PDF exportado del notebook ejecutado (File → Print → Guardar como PDF).
- Enlace público del notebook o repositorio del grupo en GitHub.
- Evidencia de carga de la base PMD1 desde la URL RAW de GitHub.
- Tabla de porcentaje de aporte por integrante completada y honesta.
- Tablas normalizadas guardadas en SQLite y reporte final con JOIN ejecutado.

IX. CONCLUSIONES GRUPALES

El grupo redacta tres conclusiones técnicas y de aprendizaje:

1. _____
2. _____
3. _____

X. RÚBRICA HOLÍSTICA DE EVALUACIÓN

Criterios a evaluar	Excelente	Bueno	Requiere mejora	No aceptable
Carga y contexto PMD1	Carga la base desde GitHub (RAW), describe con precisión el negocio, muestra estructura y primeras filas correctamente.	Carga la base y describe el negocio de manera general.	Carga la base, pero la descripción es superficial o incompleta.	No carga la base desde GitHub o no presenta contexto del caso.
Diagnóstico y limpieza de datos	Identifica completamente nulos, duplicados, tipos incorrectos y aplica limpieza justificada con evidencia antes/después.	Identifica y corrige la mayoría de problemas de calidad.	Detecta algunos problemas, pero la limpieza es parcial o poco justificada.	No realiza diagnóstico o limpieza adecuada.
Tratamiento de outliers y normalización numérica	Aplica IQR con justificación de negocio, documenta decisiones y normaliza correctamente verificando resultados.	Trata outliers y normaliza, aunque con justificación o validación parcial.	Realiza solo uno de los procesos o los aplica incorrectamente.	No trata outliers ni normaliza los datos.
Normalización relacional y SQLite	Construye tablas maestras y transaccionales, asigna claves primarias, almacena en SQLite y verifica integridad mediante JOIN.	Construye las tablas principales, pero presenta detalles incompletos en claves o JOIN.	Intenta normalizar, pero existen errores de estructura o relaciones.	No realiza normalización relacional.
Análisis y respuestas reflexivas	Respuestas técnicas, contextualizadas y sustentadas con resultados obtenidos en el notebook.	Respuestas pertinentes, pero con limitada	Respuestas breves o parcialmente relacionadas con el caso.	Respuestas ausentes o irrelevantes.

		profundidad analítica.		
--	--	------------------------	--	--

Descripción de niveles

Nivel	Descripción
Excelente (14–16)	El grupo carga su base PMD1 desde GitHub, diagnostica con profundidad los problemas de calidad, aplica la limpieza completa (nulos, duplicados, tipos, texto), trata outliers con criterio de negocio, normaliza variables numéricas y construye las tablas relacionales con claves primarias y un JOIN que verifica la conservación de datos. Las respuestas reflexivas son precisas y contextualizadas en el caso PMD1.
Bueno (14–12)	El grupo carga la base y diagnostica los principales problemas. La limpieza cubre la mayoría de los aspectos requeridos. El tratamiento de outliers y la normalización numérica están presentes, aunque algún paso es parcial. La normalización relacional construye las tablas principales pero el JOIN o la asignación de claves es incompleta. Las respuestas reflexivas son pertinentes, pero con poca profundidad.
Requiere mejora (09–12)	El grupo carga la base, pero el diagnóstico es superficial. La limpieza omite pasos importantes. El tratamiento de outliers o la normalización numérica está incompleto o sin justificación. La normalización relacional intenta separar tablas, pero sin claves correctas ni JOIN. Las respuestas reflexivas son breves o fuera de contexto.
No aceptable (00–08)	El notebook no ejecuta, la base no se carga desde GitHub o el pipeline de limpieza está vacío o copiado sin adaptación. No se realizó normalización relacional. Las respuestas están ausentes o son irrelevantes.

Acciones a cumplir (Menos)

Acciones a cumplir	Menos
Puntualidad y dedicación	1
Cumplimiento de tiempos establecidos	1
Conclusiones: ortografía y redacción	1

Puntaje total: 20 puntos.

XII. MATERIAL COMPLEMENTARIO

- Laboratorio Dirigido N.º 05: Python, pandas, normalización y EDA básico.
- Laboratorio Dirigido N.º 06: Pipeline de limpieza de datos.
- McKinney, W. (2022). Python for Data Analysis. O'Reilly Media.
- Ilyas, I. F. y Chu, X. (2019). Data Cleaning. ACM Books.
- Documentación oficial de pandas: <https://pandas.pydata.org/docs/>
- SQLite con Python: <https://docs.python.org/3/library/sqlite3.html>