



Pasión por la Tecnología

Fundamentos de Gestión de Datos

Docente:
Pilar Rocío Sayán Mejía

Laboratorio n° 07

**Semana 7:
ML Supervisado –
Regresión y Clasificación**



Laboratorio Dirigido N° 07 Tema: ML Supervisado - Regresión Lineal con scikit-learn	
DOCENTE: Pilar Rocío Sayán Mejía	CURSO: Fundamentos de Gestión de Datos

I. ELEMENTO DE LA CAPACIDAD TERMINAL

Entrena un modelo de regresión lineal sobre el dataset limpio almacenado en SQLite, aplica el proceso CRISP-DM, evalúa el rendimiento con las métricas R^2 , MSE y RMSE, interpreta los coeficientes y el gráfico de residuos para determinar la capacidad predictiva y apoyar la toma de decisiones.

II. SEGURIDAD

- Está prohibida la manipulación de hardware o conexiones eléctricas/de red sin supervisión.
- No consumir alimentos ni bebidas durante la sesión.
- Guardar maletines y mochilas en el lugar asignado.
- Dejar la mesa de trabajo y la silla limpias y ordenadas.
- No instalar software no autorizado.
- Todo el desarrollo se realiza en Google Colab con acceso a la base de datos SQLite del proyecto.

III. FUNDAMENTO TEÓRICO

Lecturas previas:

- Diapositivas de la Semana 7: ML Supervisado — Regresión y Clasificación.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O'Reilly. Capítulo 4.
- James, G. et al. (2021). *An Introduction to Statistical Learning*. Springer. Capítulos 2 y 3.
- Documentación scikit-learn: https://scikit-learn.org/stable/modules/linear_model.html

Conceptos clave: Machine Learning, aprendizaje supervisado, regresión lineal, variable dependiente, variable independiente, CRISP-DM, coeficiente (β), intercepto, train/test split, overfitting, underfitting, coeficiente de determinación (R^2), error cuadrático medio (MSE), raíz del error cuadrático medio (RMSE), residuos, scikit-learn.

IV. RECURSOS

- Computadora con acceso a internet y navegador web.
- Cuenta de Google para acceder a Google Colab.

- Base de datos SQLite con la tabla limpia del proyecto (ventas_limpio o equivalente, resultado del Lab D6).
- Librerías: pandas, numpy, matplotlib, seaborn, sklearn (preinstaladas en Colab).

V. METODOLOGÍA PARA EL DESARROLLO

El laboratorio se desarrolla de forma **individual**. Duración estimada: 2 horas.

Entregable: Notebook .ipynb ejecutado con código, gráficos y respuestas completas a todas las preguntas.

VI. PROCEDIMIENTO

ACTIVIDAD 1: Revisión de conceptos — ML Supervisado

Completa la siguiente tabla con tus propias palabras (**no copiar definiciones textuales**). Cada respuesta debe reflejar tu comprensión del concepto.

Nº	Concepto / Pregunta	Definición con sus propias palabras
1	¿Qué es el Machine Learning? ¿Diferencia entre supervisado y no supervisado?	
2	¿Cuáles son las 6 fases del proceso CRISP-DM? Descríbelas brevemente.	
3	¿Qué es la regresión lineal? ¿Qué representa el coeficiente (β) de cada variable?	
4	¿Qué mide el R^2 ? ¿Un $R^2 = 0.85$ indica un buen o mal modelo?	
5	¿Qué son el MSE y el RMSE? ¿Cómo se interpretan en el contexto del negocio?	
6	¿Qué es el train/test split? ¿Por qué NO se debe entrenar con el 100 % de los datos?	
7	¿Qué es el overfitting? ¿Cómo se detecta comparando R^2 de train y test?	
8	¿Qué son los residuos y qué patrón esperamos en un modelo bien ajustado?	

ACTIVIDAD 2: Desarrollo práctico — Regresión lineal con scikit-learn

En esta actividad entrenas un modelo de regresión lineal sobre el dataset limpio del proyecto. Los datos se leen directamente desde SQLite. Sigue el proceso CRISP-DM: comprensión de datos → preparación → modelado → evaluación.

Paso 1: Cargar datos limpios desde SQLite

```
import sqlite3
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score, mean_squared_error

# Cargar tabla limpia del Lab D6
conn = sqlite3.connect('proyecto.db')
df = pd.read_sql_query("SELECT * FROM ventas_limpio", conn)
conn.close()

print(f"Dataset cargado: {df.shape[0]} filas × {df.shape[1]} columnas")
print("\nColumnas disponibles:")
print(df.dtypes)
df.head()
```

Pregunta 1: ¿Cuántos registros tiene la tabla limpia? ¿Qué columna usarás como variable objetivo (target)? Justifica tu elección en función del caso de negocio.

Respuesta:

Paso 2: Análisis de correlación y selección de variables

```
# Matriz de correlación
num_df = df.select_dtypes(include=['number'])
corr_matrix = num_df.corr()

plt.figure(figsize=(10, 8))
sns.heatmap(corr_matrix, annot=True, fmt='.2f', cmap='Blues',
            linewidths=0.5, linecolor='white')
plt.title('Matriz de correlación — Variables numéricas', fontsize=13)
plt.tight_layout()
plt.show()

# Mostrar correlación con la variable objetivo
target = 'monto_venta' # Cambiar según tu dataset
print(f"\nCorrelación con '{target}':")
print(corr_matrix[target].sort_values(ascending=False))
```

Pregunta 2: ¿Qué variables tienen mayor correlación con tu variable objetivo? ¿Cuáles excluyes y por qué? (Considera evitar multicolinealidad.)

Respuesta:

Paso 3: Preparar features y target — split 80/20

```
# Definir variables (ajustar según tu dataset)
features = ['cantidad', 'precio_unitario', 'descuento'] # Cambiar según tu caso
target = 'monto_venta'

X = df[features]
y = df[target]

# Split 80% entrenamiento / 20% prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"Entrenamiento: {X_train.shape[0]} registros ({X_train.shape[0]/len(df)*100:.0f}%)")
print(f"Prueba:      {X_test.shape[0]} registros ({X_test.shape[0]/len(df)*100:.0f}%)")
```

Pregunta 3: ¿Por qué usamos random_state=42? ¿Qué pasaría si usamos un split de 50/50 en lugar de 80/20?

Respuesta:

Paso 4: Entrenamiento e interpretación de coeficientes

```
# Entrenar modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)

# Ver coeficientes
coef_df = pd.DataFrame({
    'Variable': features,
    'Coeficiente': modelo.coef_
}).sort_values('Coeficiente', ascending=False)

print("Intercepto:", round(modelo.intercept_, 4))
print("\nCoeficientes del modelo:")
print(coef_df.to_string(index=False))
```

Pregunta 4: Interpreta los coeficientes. ¿Qué variable tiene mayor impacto en la predicción? Si el coeficiente de 'precio_unitario' es 0.75, ¿qué significa en términos de negocio?

Respuesta:

Paso 5: Evaluación con métricas R^2 , MSE y RMSE

```
# Predicciones sobre el conjunto de prueba
y_pred = modelo.predict(X_test)

# Calcular métricas
r2 = r2_score(y_test, y_pred)
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)

print(f'R² = {r2:.4f} → El modelo explica el {r2*100:.1f}% de la varianza')
print(f'MSE = {mse:.4f} → Error cuadrático medio')
print(f'RMSE = {rmse:.4f} → Error promedio en unidades de la variable objetivo')

# R² en entrenamiento (para detectar overfitting)
r2_train = modelo.score(X_train, y_train)
print(f'\nR² entrenamiento = {r2_train:.4f}')
print(f'R² prueba = {r2:.4f}')
print(f'Diferencia = {abs(r2_train - r2):.4f} ',
      '⚠ Posible overfitting' if abs(r2_train - r2) > 0.1 else '✓ Sin overfitting significativo')
```

Pregunta 5: ¿El modelo presenta overfitting o underfitting? ¿Cómo lo determinaste? ¿El RMSE obtenido es aceptable para el negocio?

Respuesta:

Paso 6: Visualizaciones — residuos y valores predichos vs. reales

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Gráfico 1: Valores reales vs. predichos
axes[0].scatter(y_test, y_pred, alpha=0.5, color='steelblue', edgecolors='white', s=30)
axes[0].plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'r--', lw=2)
axes[0].set_xlabel('Valores reales')
axes[0].set_ylabel('Valores predichos')
axes[0].set_title(f'Real vs. Predicho (R²={r2:.3f})')

# Gráfico 2: Residuos
residuos = y_test - y_pred
axes[1].scatter(y_pred, residuos, alpha=0.5, color='coral', edgecolors='white', s=30)
axes[1].axhline(y=0, color='black', linestyle='--', lw=1.5)
axes[1].set_xlabel('Valores predichos')
axes[1].set_ylabel('Residuos')
axes[1].set_title('Gráfico de residuos')
```

```
plt.tight_layout()
plt.show()
```

Pregunta 6: ¿Los residuos se distribuyen aleatoriamente alrededor del cero? ¿Qué indican los patrones en el gráfico de residuos sobre la calidad del modelo?

Respuesta:

ACTIVIDAD 3: Caso contextualizado — MercadoPerú S.A.

El equipo de Analytics de **MercadoPerú S.A.** entrenó un modelo de regresión lineal para predecir el monto de cada pedido. El Comité de Proyecciones debe decidir si el modelo es confiable para proyectar los ingresos del tercer trimestre 2026. El modelo obtuvo **$R^2=0.79$ en entrenamiento y $R^2=0.61$ en prueba**, con un **RMSE de S/. 45.20..**

Pregunta A

¿El modelo obtenido por MercadoPerú presenta overfitting? ¿Cómo lo determinaste con los valores R^2 de train y test?

Respuesta:

Pregunta B

Con un RMSE de S/. 45.20 en una empresa con ticket promedio de S/. 180, ¿el modelo es preciso? ¿Recomendarías usarlo para proyecciones de negocio?

Respuesta:

Pregunta C — Decisión Ejecutiva

Redacta un párrafo ejecutivo para el Comité de Proyecciones explicando: qué predice el modelo, qué tan confiable es (sin términos técnicos), y qué acción recomiendas (usarlo, mejorarlo o descartarlo?).

Respuesta:

Pregunta D — Inferencia

Si agregaras la variable 'ciudad' (categórica con 15 valores) al modelo usando one-hot encoding, ¿crees que el R^2 mejoraría o empeoraría? ¿Qué riesgo traería agregar 15 variables nuevas?

Respuesta:

VII. CONCLUSIONES

Redacta 3 conclusiones que sintetizen lo aprendido en este laboratorio:

1. _____

2. _____

3. _____

VIII. MATERIAL COMPLEMENTARIO

4. Géron, A. (2022). Hands-On Machine Learning. O'Reilly. Capítulo 4.
5. James, G. et al. (2021). An Introduction to Statistical Learning. Springer. Capítulo 3.
6. Scikit-learn — LinearRegression: https://scikit-learn.org/stable/modules/linear_model.html
7. Documentación matplotlib/seaborn para visualización de residuos.

IX. RÚBRICA DE EVALUACIÓN

Criterio	Excelente (5)	Bueno (4)	En desarrollo (2)	Insuficiente (1)	Pts.
Carga y selección de variables (Pasos 1–2)	Carga la tabla limpia desde SQLite correctamente. Presenta heatmap de correlación completo. Selecciona ≥ 3 features con justificación basada en correlación y sin multicolinealidad evidente.	Carga correcta, heatmap presente, selecciona features pero sin justificación explícita de multicolinealidad.	Carga correcta pero heatmap ausente o mal interpretado; selección de features sin criterio.	No carga desde SQLite o usa <code>df.read_csv()</code> en lugar de <code>pd.read_sql_query()</code> .	/3
Entrenamiento e interpretación de coeficientes (Pasos 3–4)	Split 80/20 correcto con <code>random_state</code> . Coeficientes interpretados en unidades del negocio ("por cada S/. 1 de descuento, el monto aumenta/disminuye en S/. X"). Identifica la variable de mayor impacto.	Split correcto, coeficientes listados pero interpretación genérica (no en unidades del negocio).	Split incorrecto (ratio diferente o sin <code>random_state</code>) o coeficientes sin interpretación.	No entrena el modelo o el código tiene errores que impiden ejecutarse.	/3

Criterio	Excelente (5)	Bueno (4)	En desarrollo (2)	Insuficiente (1)	Pts.
Métricas R², MSE y RMSE (Paso 5)	Las 3 métricas calculadas en test y R ² también en train. Determina correctamente si hay overfitting comparando ambos R ² . Interpreta el RMSE en unidades del negocio (e.g., "el error promedio de predicción es S/. XX").	Las 3 métricas calculadas. Menciona overfitting pero sin comparar R ² train vs. test.	Solo calcula R ² o solo MSE/RMSE. No interpreta en contexto de negocio.	No calcula métricas o los valores son incorrectos (ej. MSE negativo).	/4
Visualizaciones (Paso 6)	Ambos gráficos presentes (real vs. predicho Y residuos). Interpreta que los puntos del gráfico de residuos deben estar aleatoriamente distribuidos alrededor del cero para un modelo válido. Identifica si hay patrones.	Ambos gráficos presentes pero solo menciona si los puntos están "cerca" de la línea sin analizar los residuos.	Solo un gráfico presente o gráficos sin títulos/etiquetas.	No genera visualizaciones o las celdas tienen errores sin resolver.	/4
Análisis ejecutivo — Actividad 3	Párrafo ejecutivo (C) claro, sin jerga, menciona nivel de confiabilidad con evidencia del R ² /RMSE. Recomendación concreta. Pregunta D analiza trade-off de añadir features con riesgo de overfitting mencionado.	Párrafo ejecutivo presente pero usa términos técnicos (R ² , RMSE) sin explicarlos. Pregunta D responde sin mencionar el riesgo de overfitting.	Solo responde 1–2 preguntas superficialmente sin conectar con el caso MercadoPerú.	No completa la Actividad 3 o respuestas copiadas textualmente de internet.	/4
Puntualidad en la entrega (bonus)	Entrega antes o en la hora exacta indicada en el aula virtual.	Entrega con 1–10 minutos de retraso.		Entrega con más de 10 minutos de retraso o no entrega.	/1
Conclusiones (redacción y ortografía)	3 conclusiones bien redactadas, sin faltas, que conectan aprendizaje técnico	2 conclusiones con mínimas faltas ortográficas.		Solo 1 conclusión o repiten el enunciado.	/1

Criterio	Excelente (5)	Bueno (4)	En desarrollo (2)	Insuficiente (1)	Pts.
	con aplicación al negocio.				
TOTAL					/20

Acciones a cumplir:	
Puntualidad en la entrega:	0 / 1 pt ____
Conclusiones (redacción y ortografía):	0 / 1 pt ____
Puntaje total:	____ / 20

Comentarios del docente:
